Agora que já sabemos as etapas do **aprendizado supervisionado** e como identificar qual será o tipo de modelagem que iremos aplicar ao nosso problema, entraremos na **última parte da preparação dos nossos dados** antes de fato começarmos a montar nosso algoritmo de aprendizado de máquina.

ETAPA 3.1:
CORRELAÇÃO

As principais etapas pré modelagem

Tratamento dos Dados

Realizar tratamento dos tipos de dados, dados ausentes, dados nulos ou dados preenchidos de forma incorreta. Assim como aprendemos a corrigir esses problemas.

Objetivo: Garantir a qualidade e a integridade dos dados, o que pode afetar diretamente o desempenho e a precisão do modelo.

Identificação de Outliers

Outro fator que afeta diretamente os modelos e seu desempenho é a presença de outliers, aprendemos a identificar, analisar e tratar esses dados quando necessário.

Objetivo: Outliers podem distorcer a estimativa dos parâmetros do modelo, levando a uma estimativa imprecisa dos efeitos das variáveis independentes sobre a variável dependente

Correlação

Agora aprenderemos a analisar a correlação entre nossas variáveis antes de aplicarmos o modelo.

Objetivo: A correlação pode ajudar a identificar quais variáveis têm uma relação mais forte, Variáveis altamente correlacionadas com a variável alvo tendem a fornecer mais informações úteis para o modelo e com a variável de resposta

CORRELAÇÃO NA PRÁTICA:

Imagine que você está **considerando comprar um carro** e está analisando diferentes fatores para tomar sua decisão. Você percebe que, **sempre que o preço do combustível aumenta**, **você tende a usar menos o carro** e opta por usar mais transporte público ou bicicleta para economizar dinheiro. Por outro lado, **quando o preço do combustível diminui**, você se sente mais inclinado a **usar o carro com mais frequência**, seja para ir ao trabalho, viajar ou fazer outras atividades.

Agora, pense em outro fator, como o estado do trânsito na sua cidade. Se você observar que**, nos dias em que o trânsito** está muito congestionado, você **prefere deixar o carro em casa** e utilizar transporte público ou outras alternativas, isso indica uma correlação entre o trânsito e o uso do carro.

Em resumo, correlações no contexto do uso de carros no dia a dia podem ser observadas em como **diferentes fatores, como preço do combustível e estado do trânsito, influenciam suas decisões sobre quando e como utilizar o carro.**

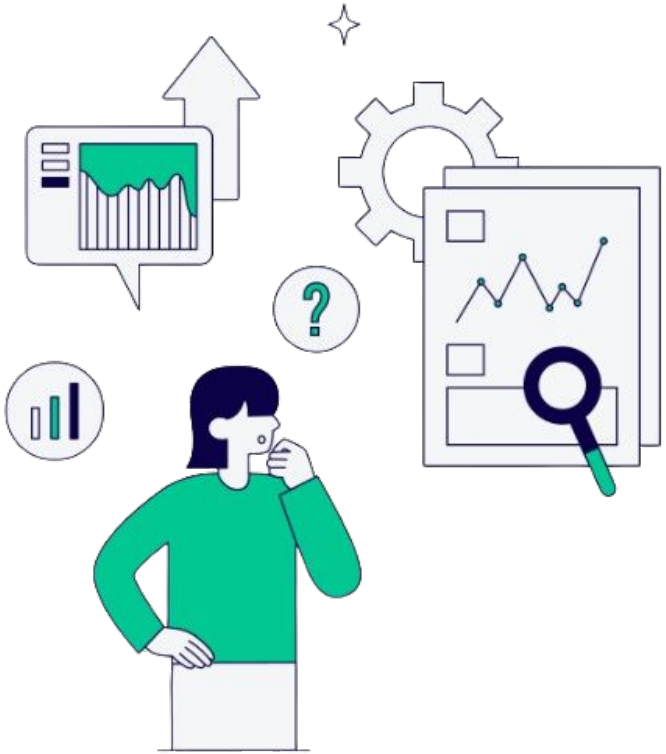

Basicamente, correlação é sobre como duas coisas estão relacionadas uma com a outra. Se elas mudam juntas na mesma direção (ambas ficam mais fortes ou mais fracas), dizemos que têm uma correlação positiva. Se elas mudam em direções opostas (uma fica mais forte enquanto a outra fica mais fraca), é uma correlação negativa. E se não parece haver nenhuma relação entre elas, dizemos que têm uma correlação nula ou fraca.

ETAPA 3.1:
CORRELAÇÃO

CORRELAÇÃO LINEAR POSITIVA

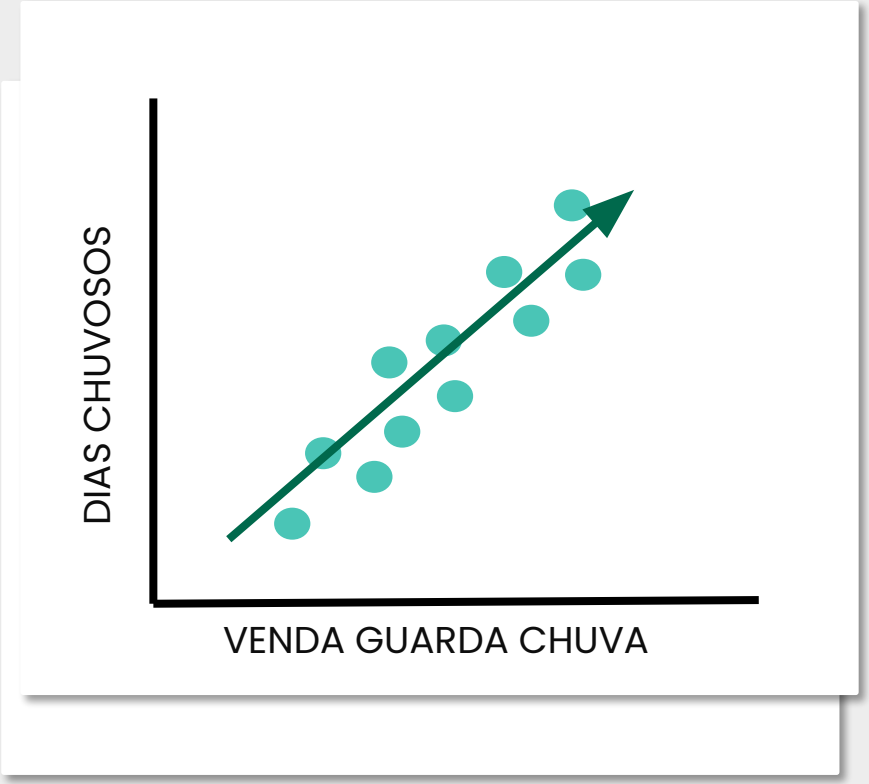

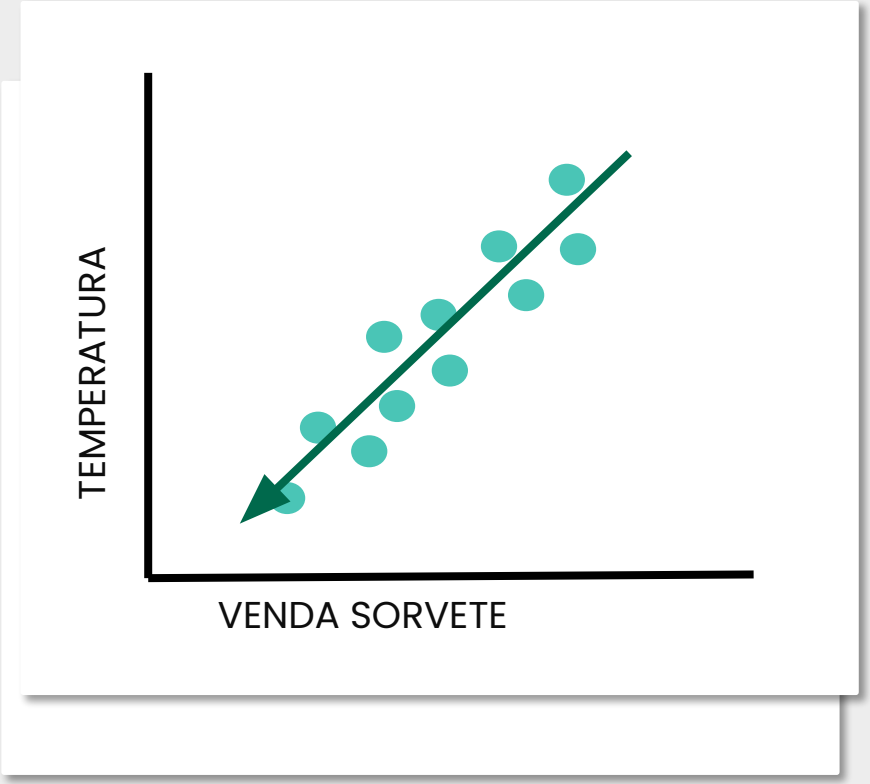

CORRELAÇÃO LINEAR NEGATIVA

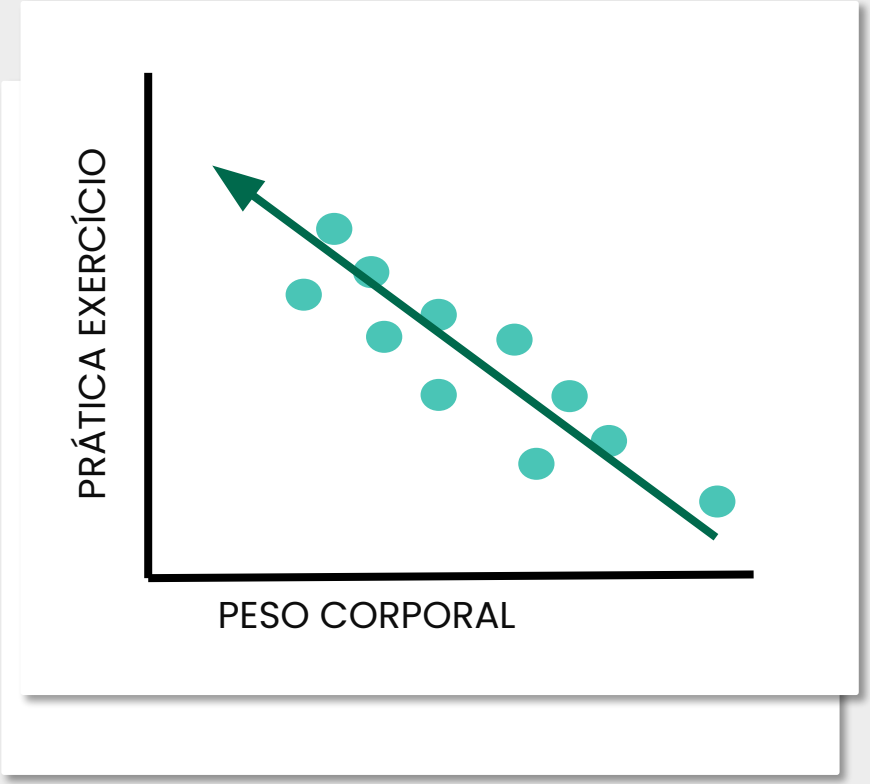

BAIXA CORRELAÇÃO LINEAR

Coeficiente de Correlação Linear (Pearson)

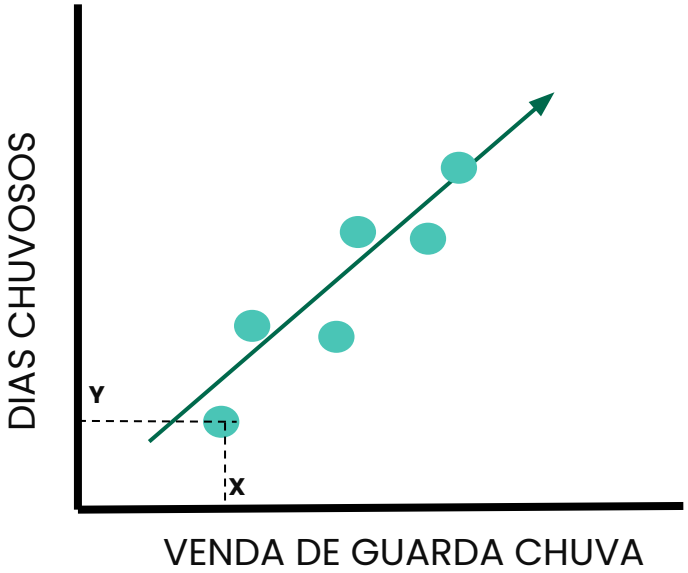

$$r = \frac{\sum_{i=1}^{n}[(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2 \times \sum_{i=1}^{n}(Y_i - \bar{Y})^2}}$$

$$r = \frac{n(\sum xy) - (\sum x)(\sum y)}{\sqrt{[\,n\sum x^2 - (\sum x)^2\,]\,[\,n\sum y^2 - (\sum y)^2\,]}}$$

O COEFICIENTE VARIA ENTRE -1 E 1

Coeficiente de Correlação Linear

	X (venda gc)	Y (horas chovidas)	X^2	Y^2	XY
	10	4	100	16	40
	16	6	256	36	96
	3	1	9	1	3
SOMATÓRIA	29	11	365	53	139

COEFICIENTE CORRELAÇÃO:

$$\frac{3*139 - 29*11}{\sqrt{3*365 - 29^2} * \sqrt{3*53 - 11^2}} = 0{,}9993$$

CORRELAÇÃO

TEM RELAÇÃO COM O AJUSTE NA RETA E NÃO NECESSARIAMENTE INCLINAÇÃO

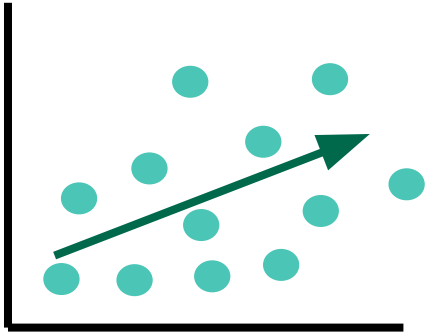

0.3

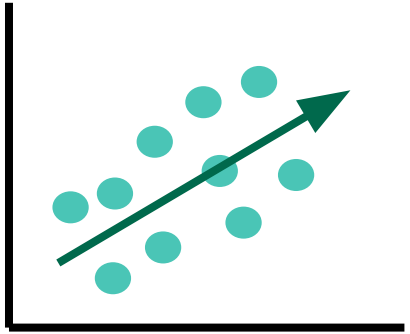

0.5

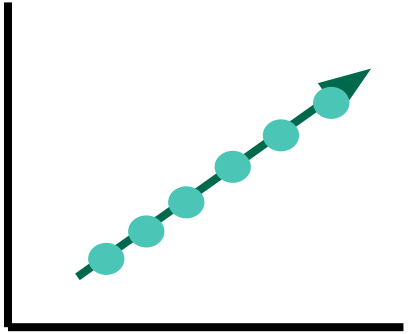

1.0