

01

Implementação

Aplicar o modelo na base real e colocar o modelo em produção usando plataformas.

Nesta etapa costumamos realizar algumas tarefas:

- Documentação e Limpeza do Código.
- Escolha da ferramenta para alimentação dos dados (Geralmente cada empresa tem a sua)
- Integração com APIs.

O objetivo dessa etapa é documentar e garantir que o modelo fará previsões com dados reais.



Limpeza e Documentação

Certifique-se de que o código esteja bem documentado e limpo para facilitar a manutenção futura, antes de você subir o código no github, por exemplo. Isso inclui comentários claros e documentação detalhada do funcionamento do modelo. Sabe aqueles códigos de teste e rascunho? É hora de apagar e deixar apenas o necessário e funcional.

Ferramentas

O modelo deverá realizar previsões com a base real, não mais dados de treino e teste, a ideia é que ele realize previsões com todos os dados novos da empresa.

Ferramentas como AWS, Google Cloud, Azure são utilizadas para hospedar e operar modelos em produção. Cada uma dessas plataformas oferece serviços específicos para deploy de modelos, como AWS SageMaker, Google AI Platform, e Azure Machine Learning.



**Engenheiros de
Software ou Dados**

Integração

Permitir que seu modelo seja acessível por outros serviços, aplicações ou usuários de forma programática.

Criar endpoints que permitam a interação com o modelo.

Realizar testes rigorosos para assegurar a funcionalidade correta da API.

Essa abordagem garante que seu modelo de machine learning seja facilmente acessível e utilizável em diferentes contextos.



**Engenheiros de
Software ou Dados**

02


Monitoramento

Contínuo

Monitorar a performance do modelo em tempo real para identificar qualquer degradação.

Nesta etapa costumamos realizar algumas tarefas:

- O monitoramento contínuo é uma prática essencial para garantir que os modelos de machine learning mantenham sua eficácia e eficiência após serem implantados em produção. Ele envolve a coleta de métricas, a configuração de alertas, o ajuste dinâmico do modelo, e a colaboração contínua entre cientistas de dados e engenheiros de infraestrutura para garantir que qualquer problema seja rapidamente identificado e resolvido.





Métricas de Avaliação

O modelo é configurado para exportar métricas de performance (e.g., acurácia, tempo de resposta) para uma ferramenta de monitoramento.

Criação de ferramenta

Desenvolvemos um dashboard **para monitoramento** para acompanhar as previsões do modelo na base real.

Logs e Alertas

Configuramos alertas para disparar caso nossas métricas estejam muito baixas, assim garantimos que o modelo continua entregando as previsões corretamente.




Por que monitorar o modelo?

Imagine que treinamos um modelo, com o objetivo de entender quais os clientes com maior propensão a compra, e que suas principais variáveis são idade e gênero, quando treinamos nossos principais clientes eram homens entre 20 e 30 anos.

Após 1 ano do modelo ativo, nossos clientes tem um perfil completamente diferente, hoje temos mulheres entre 40 e 50 anos.

Com essa mudança brusca no perfil dos nossos clientes o modelo estará fazendo previsões incorretas.

Ao monitorar o modelo poderemos notar uma diminuição nas






Manutenção

Com o tempo, o modelo pode precisar ser re-treinado com novos dados para manter a precisão.

Nesta etapa costumamos realizar algumas tarefas:

A manutenção e atualização de um modelo de machine learning são essenciais para garantir que ele continue a fornecer previsões precisas e úteis à medida que o ambiente de produção e os dados mudam ao longo do tempo. Nessa etapa retreinamos o modelo quando necessário.



O retreino do modelo

Como no exemplo que demos anteriormente, com a mudança nos dados nosso modelo passará a fazer previsões incorretas.

Com isso se fará necessário refazer a etapa de treino do modelo.

Ao invés de utilizarmos a base inteira, com dados passados, treinamos nossos modelos com um intervalo de dados mais recente, buscando capturar essa mudança dos dados da base.

