




Sobre o Módulo:

Neste módulo, nosso objetivo é revisar e aprofundar as métricas de avaliação de modelos, garantindo que vocês tenham um entendimento sólido e aplicável desses conceitos fundamentais. Muitos de vocês ainda não atuam profissionalmente na área de ciência de dados, o que pode levar a uma eventual perda desses conceitos ao longo do tempo. Por isso, queremos aproveitar esta oportunidade para explorar detalhadamente cada métrica, discutindo onde e quando aplicá-las de forma eficaz.



Sobre o Módulo:

Além disso, vamos abordar os hiperparâmetros dos modelos, um tema que já exploramos brevemente no nosso duelo de modelos e no módulo de árvore de decisão. No entanto, nunca mergulhamos profundamente nesse assunto. Agora, vamos entender melhor como ajustar esses parâmetros para melhorar o desempenho dos nossos modelos e maximizar a eficácia das nossas análises.





Acurácia

Proporção de previsões corretas em relação ao total de previsões feitas.

É calculada dividindo o número de previsões corretas pelo número total de previsões. Embora seja uma métrica intuitiva e fácil de interpretar, a acurácia pode ser enganosa em casos de classes desbalanceadas, onde o modelo pode ter uma alta acurácia simplesmente prevendo a classe majoritária.

Onde usar:

Modelos de classificação, como árvore de decisão, regressão logística e outros.

Onde não usar:

Regressão Linear e Polinomial.

Alertas:

Pode ser menos informativa em classificação desbalanceada, onde métricas como F1 score, precisão e recall são mais úteis para avaliar o desempenho do modelo.



02

Recall

Proporção de verdadeiros positivos identificados pelo modelo em relação ao total de casos positivos reais.

O recall (ou sensibilidade) mede a capacidade do modelo de identificar corretamente todos os casos positivos em um conjunto de dados. É calculado dividindo o número de verdadeiros positivos pelo número total de casos **positivos reais**. Essa métrica é particularmente útil em situações onde é crucial detectar todos os casos positivos, como em diagnósticos médicos, onde não identificar uma condição pode ter consequências graves.

Onde usar:

Modelos de classificação, como árvore de decisão, regressão logística e outros.

Onde não usar:

Regressão Linear e Polinomial.

Alertas:

Um alto recall pode levar a um aumento no número de falsos positivos, o que pode ser problemático em contextos onde a precisão é igualmente importante.



03

Precisão

Proporção de verdadeiros positivos identificados pelo modelo em relação ao total de casos positivos previstos pelo modelo.

A precisão mede a capacidade do modelo de prever corretamente apenas os casos positivos em relação ao total de **previsões positivas feitas**. É calculada dividindo o número de verdadeiros positivos pelo número total de casos positivos previstos (a soma de verdadeiros positivos e falsos positivos).

Onde usar:


Modelos de classificação, como árvore de decisão, regressão logística e outros.

Onde não usar:

Regressão Linear e Polinomial.

Alertas:

Uma alta precisão pode resultar em um recall baixo, indicando que o modelo pode estar perdendo muitos casos positivos.




Trade Off entre Recall e Precisão:

Precisão é a proporção de verdadeiros positivos entre todas as previsões positivas feitas pelo modelo. Em outras palavras, é a precisão de identificar apenas os casos positivos corretos entre os casos que o modelo previu como positivos. Se a precisão é alta, isso significa que a maioria das previsões positivas feitas pelo modelo são realmente corretas.

Recall, por outro lado, é a proporção de verdadeiros positivos identificados pelo modelo entre todos os casos positivos reais. Em outras palavras, é a capacidade do modelo de identificar todos os casos positivos reais.

Quando um modelo é projetado para ter uma alta precisão, ele tende a ser mais conservador em fazer previsões positivas. Isso significa que ele só fará previsões positivas quando estiver bastante certo de que a previsão é correta. Como resultado, ele pode acabar prevendo



04

F1 Score

Métrica que combina precisão e recall em uma única medida, calculada como a média harmônica entre esses dois

valores. O F1 Score é uma métrica que balanceia a precisão e o recall para fornecer uma avaliação mais completa do desempenho do modelo, especialmente útil em situações onde há um trade-off entre esses dois aspectos. O F1 Score é calculado como a média harmônica entre a precisão e o recall, oferecendo uma única pontuação que reflete a harmonia entre a capacidade do modelo de identificar corretamente casos positivos e sua capacidade de evitar falsos positivos. Essa métrica é

Onde usar:

Modelos de classificação, como árvore de decisão, regressão logística e outros.

Onde não usar:

Regressão Linear e Polinomial.

Alertas:

O F1 Score pode ser útil em muitos cenários, mas não captura a importância de diferentes tipos de erros em todas as aplicações.

Em situações onde os custos de falsos positivos e falsos negativos são significativamente diferentes é

05

R quadrado

Mede a proporção da variabilidade dos dados que é explicada pelo modelo de regressão.

O R^2 é uma métrica usada em modelos de regressão para avaliar a proporção da variabilidade dos dados que é explicada pelo modelo. É calculado como 1 menos a razão entre a soma dos quadrados dos erros (resíduos) e a soma total dos quadrados. Um valor de R^2 próximo de 1 indica que o modelo explica bem a variabilidade dos dados, enquanto um valor próximo de 0 sugere que o modelo não explica muito da variabilidade

Onde usar:

Modelos de regressão, como regressão linear simples, múltipla e polinomial.

Onde não usar:

Modelos de classificação e modelos com resíduos com difícil distribuição.

Alertas:

Ele não captura a complexidade dos dados e pode ser enganoso se o modelo for ajustado excessivamente aos dados (overfitting).

