


Regressão Lasso, Ridge e Elastic Net


Vamos explorar três tipos de regressão que são muito úteis para melhorar a performance dos nossos modelos, especialmente quando lidamos com dados complexos ou muitos atributos. Esses métodos são conhecidos como Regressão Ridge, Regressão Lasso e Elastic Net. Talvez esses nomes já tenham soado familiares, pois discutimos esses conceitos ao otimizar hiperparâmetros dos nossos modelos.

Esses métodos ajudam a ajustar o modelo para obter melhores previsões e lidar com dados de forma mais eficiente. Eles são parte fundamental do que aprendemos sobre otimização de hiperparâmetros, pois ajustamos esses métodos para encontrar o melhor desempenho do modelo.



Regressão Lasso, Ridge e Elastic Net

Você aplica métodos como Regressão Ridge, Lasso e Elastic Net principalmente quando deseja prevenir o overfitting, que é quando um modelo se ajusta demais aos dados de treino e tem um desempenho ruim em dados novos. Esses métodos são úteis quando você lida com muitos atributos ou variáveis correlacionadas, ajudando a regularizar o modelo e, em alguns casos, realizar a seleção de atributos para simplificar o modelo. Eles ajudam a melhorar a performance geral e a capacidade de generalização do modelo, resultando em previsões mais robustas e confiáveis.



Regressão Lasso


- Objetivo: Reduzir o risco de overfitting e realizar a seleção de variáveis, promovendo a simplicidade do modelo.
- Como Funciona: Adiciona um termo de penalização à função de custo do modelo de regressão. Esse termo é baseado na soma dos valores absolutos dos coeficientes dos atributos.
- Penalização: A penalização L1 é calculada como a soma dos valores absolutos dos coeficientes multiplicada por um parâmetro de regularização.

$$\text{Custo} = \text{Erro Quadrático Médio} + \lambda \cdot \sum_{i=1}^n |\beta_i|$$



Regressão Lasso: Efeitos

- Redução de Coeficientes: A penalização L1 tende a reduzir alguns coeficientes a exatamente zero. Isso efetivamente elimina algumas variáveis do modelo, o que ajuda na seleção de atributos e na simplificação do modelo.
- Simplicidade: Modelos com menos variáveis são mais simples e mais fáceis de interpretar, além de serem menos propensos ao overfitting.
- Seleção de Variáveis: Ao forçar alguns coeficientes a zero, o Lasso realiza uma forma de seleção de variáveis, mantendo apenas as mais relevantes para o modelo.



Regressão Ridge

- Objetivo: Reduzir o risco de overfitting e melhorar a generalização do modelo, penalizando coeficientes grandes.
- Como Funciona: Adiciona um termo de penalização à função de custo do modelo de regressão. Esse termo é baseado na soma dos quadrados dos coeficientes dos atributos.
- Penalização: A penalização L2 é calculada como a soma dos quadrados dos coeficientes multiplicada por um parâmetro de regularização

$$\text{Custo} = \text{Erro Quadrático Médio} + \lambda \cdot \sum_{i=1}^n \beta_i^2$$



Regressão Ridge: Efeitos

- Redução de Coeficientes: A penalização L2 reduz o valor dos coeficientes, mas não os elimina completamente. Isso resulta em coeficientes menores, mas não exatamente zero.
- Melhoria na Generalização: Ajuda a evitar overfitting ao penalizar coeficientes grandes, tornando o modelo mais robusto e melhor em generalizar para dados novos.
- Estabilidade: Regularização L2 tende a tornar o modelo mais estável, especialmente quando há multicolinearidade (alta correlação entre variáveis).



Regressão Elastic Net

- Objetivo: Melhorar a performance do modelo e lidar com situações onde há muitas variáveis correlacionadas, combinando os benefícios da regularização Lasso (L1) e Ridge (L2).
- Como Funciona: Adiciona dois termos de penalização à função de custo do modelo de regressão:
- Um termo L1, que realiza a seleção de variáveis e pode forçar alguns coeficientes a zero.
- Um termo L2, que penaliza grandes coeficientes para evitar overfitting.

$$\text{Custo} = \text{Erro Quadrático Médio} + \lambda_1 \sum_{i=1}^n |\beta_i| + \lambda_2 \cdot \sum_{i=1}^n \beta_i^2$$



Regressão Elastic Net: Efeitos

- Combinação de Lasso e Ridge:
- A penalização L1 permite a seleção de variáveis, mantendo apenas as mais relevantes.
- A penalização L2 ajuda a regularizar os coeficientes restantes, tornando o modelo mais robusto e melhor em generalizar para novos dados.
- Controle de Multicolinearidade: É particularmente útil quando há muitas variáveis correlacionadas. A combinação de L1 e L2 pode lidar melhor com essa correlação do que Lasso ou Ridge sozinhos.
- Flexibilidade: Oferece um equilíbrio entre a simplicidade do modelo (como no Lasso) e a estabilidade e robustez (como no Ridge).

