



Base de Treino e Teste



Vocês devem lembrar que, logo no início do curso, aprendemos a importância de dividir a base de dados em duas partes: treino e teste. Essa separação foi nossa primeira abordagem para garantir que o modelo fosse avaliado de forma justa e pudesse ser aplicado a novos dados. Até agora, essa foi a única forma que exploramos para avaliar a performance dos nossos modelos.

Separação em Treino e Teste

1

Proporção

Geralmente, separamos uma porcentagem dos dados para teste (por exemplo, 20% ou 30%) e o restante para treino.

2

Separação Aleatória


Essa divisão é feita de forma aleatória, para garantir que ambas as partes representem bem a variabilidade dos dados

3

Variação dos Dados

No entanto, a variação natural dos dados pode influenciar as bases de treino e teste, fazendo com que, em algumas divisões, o modelo possa ter desempenho melhor ou pior dependendo de como os dados foram distribuídos.

Cross Validation



Cross validation é uma técnica usada para avaliar a performance de um modelo de machine learning, dividindo os dados em várias partes, chamadas de 'folds'. O modelo é treinado em algumas dessas partes e testado nas outras, garantindo que ele seja avaliado em diferentes subconjuntos dos dados. Isso ajuda a garantir que o modelo seja robusto e tenha bom desempenho em novos dados.




Quando usar?



Modelos complexos ou pequenos conjuntos de dados:

Quando estamos trabalhando com modelos mais complexos ou quando temos uma quantidade limitada de dados, é crucial avaliar o modelo de maneira mais robusta

Comparação de modelos: Quando queremos comparar diferentes modelos ou diferentes configurações do mesmo modelo, o cross validation oferece uma avaliação mais precisa.



Porque usar:



Avaliação mais confiável: Ao invés de depender de uma única divisão entre treino e teste, o cross validation usa múltiplas divisões, o que resulta em uma avaliação mais confiável e menos sujeita a variações.

Uso eficiente dos dados: Com o cross validation, todos os dados disponíveis são utilizados tanto para treino quanto para teste, em diferentes iterações. Isso é especialmente importante quando temos uma quantidade limitada de dados.