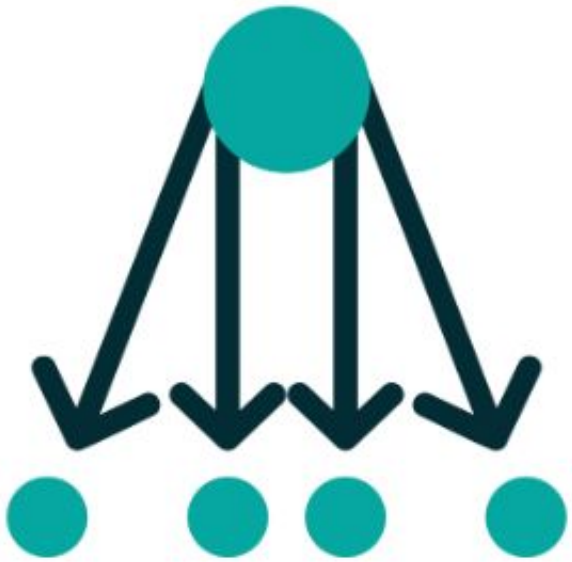

Naive Bayes

- **O que é:** O Teorema de Naive Bayes é uma técnica fundamental na área de aprendizado de máquina e em estatística, especialmente em problemas de classificação. Ele é baseado no Teorema de Bayes, que descreve como atualizar a probabilidade de uma hipótese dado um novo dado observado.
  Naive Bayes é "ingênuo" (naive) porque faz uma suposição simplificada e forte: assume que todas as features (características) são independentes entre si, o que nem sempre é verdade na prática. Apesar dessa suposição simplificada, Naive Bayes é amplamente usado e muitas vezes funciona bem em muitos cenários da vida real.

- Nós iremos aprender esse algoritmo agora, logo após estatística aplicada pois ele nos mostra claramente a relação probabilidade e aprendizado de máquina de forma simples.

EXEMPLO DE APLICAÇÃO:

Suponha que temos um conjunto de treinamento de emails rotulados como "spam" ou "não spam" . Cada email é representado por um vetor de features que consiste na frequência de palavras-chave dentro do email.
Por exemplo, podemos ter as seguintes features (palavras-chave): "oferta", "ganhar", "grátis", "comprar", etc., e a frequência com que essas palavras ocorrem em cada email.

Agora, vamos supor que recebemos um novo email e queremos determinar se ele é spam ou não spam. Usando o Teorema de Naive Bayes, podemos calcular a probabilidade de que o email seja spam ou não spam com base nas frequências das palavras-chave no email.

RISCO DE SEGURO AUTOMOTIVO

Imagine que você trabalha em uma seguradora e sua empresa está interessada em avaliar o risco associado a novos clientes que desejam contratar um seguro automotivo. O objetivo é determinar o nível de risco de sinistro que cada cliente representa, para que a empresa possa definir as taxas de prêmio de seguro apropriadas.

Para fazer essa avaliação, você possui um conjunto de dados históricos que contém informações sobre os segurados e seus respectivos históricos de sinistros de seguro automotivo. Isso inclui dados como histórico acidente, tipo de veiculo, faixa idade e o risco em si.

HISTÓRICO ACIDENTE	TIPO VEÍCULO	FAIXA IDADE	RISCO SEGURO
SIM	MOTO	ATÉ 25 ANOS	ALTO
NÃO	CARRO	ATÉ 25 ANOS	MÉDIO
NÃO	CARRO	ENTRE 25 E 40 ANOS	BAIXO
NÃO	MOTO	ENTRE 25 E 40 ANOS	MÉDIO
SIM	CARRO	ATÉ 25 ANOS	ALTO
SIM	MOTO	ENTRE 25 E 40 ANOS	ALTO

TABELA DE PROBABILIDADE

	HIST ACIDENTE		TIPO VEICULO		FAIXA IDADE	
RISCO SEGURO	SIM	NÃO	MOTO	CARRO	ATÉ 25 ANOS	ENTRE 25 E 40 ANOS
ALTO (3/6)	3/3	0	2/3	1/3	2/3	1/3
MÉDIO (2/6)	0	2/2	1/2	1/2	1/2	1/2
BAIXO (1/6)	0	1/1	0	1/1	0	1/1

APRENDIZADO:
Essa tabela representa a etapa de aprendizado do algoritmo. Sendo esse o raciocínio para classificação.

TABELA DE PROBABILIDADE

	HIST ACIDENTE		TIPO VEICULO		FAIXA IDADE	
RISCO SEGURO	SIM	NÃO	MOTO	CARRO	ATÉ 25 ANOS	ENTRE 25 E 40 ANOS
ALTO (3/6)	3/3	0	2/3	1/3	2/3	1/3
MÉDIO (2/6)	0	2/2	1/2	1/2	1/2	1/2
BAIXO (1/6)	0	1/1	0	1/1	0	1/1

Cenário fictício: Imagine que iremos determinar o risco do seguro automotivo de um cliente novo, que tem até 25 anos, o veículo é um carro e nunca foi envolvido em um acidente de carro.

TABELA DE PROBABILIDADE

Cenário fictício: Imagine que iremos determinar o risco do seguro automotivo de um cliente novo, que tem até 25 anos, o veículo é um carro e nunca foi envolvido em um acidente de carro.

P(RISCO ALTO) = (3/6)*(1/3)*(2/3) = 0.112 = 0.112/ 0.445 *100 = 25%

P(RISCO MÉDIO) = (2/6)*(2/2)*(1/2)*(1/2) = 0.167 = 0.167/ 0.445 *100 = 37%

P(RISCO BAIXO) = (1/6)*(1/1)= 0.166 = 0.166/ 0.445 *100 = 37%

Soma: 0.112+0.167+0.166 = 0.445
(Esse valor representa 100%)

*PERCEBAM QUE APENAS IGNORAMOS OS VALORES QUE SERIAM 0.